

1. Regression والـ Classification ما الفرق بين الـ

- هو عملية تقسيم البيانات إلى فئات محددة، حيث يتوقع النموذج: (Classification) التصنيف إلى أي فئة أو مجموعة تنتمي البيانات المدخلة. مثل التنبؤ إذا كانت رسالة بريد إلكتروني هي "Spam" أو "Not Spam".
- هو عملية التنبؤ بقيم رقمية مستمرة بناءً على المدخلات. يستخدم: (Regression) الانحدار. عادة للتنبؤ بأرقام دقيقة، مثل التنبؤ بسعر منزل بناءً على خصائصه.

2. Overfitting و Underfitting الفرق بين

- يحدث عندما يكون النموذج بسيطاً جداً بحيث لا يتعلم الأنماط: (Underfitting) (نقص التهيئة) الأساسية من بيانات التدريب، مما يؤدي إلى أداء ضعيف على كل من بيانات التدريب والاختبار.
- يحدث عندما يتعلم النموذج تفاصيل ودقة بيانات التدريب بشكل: (Overfitting) (فرط التهيئة) مبالغ فيه، مما يجعله غير قادر على التعميم عند تطبيقه على بيانات جديدة. هذا يؤدي إلى أداء جيد على بيانات التدريب وضعيف على بيانات الاختبار.

3. Hyperparameters و Parameters ما الفرق بين

- هي القيم التي يتعلمها النموذج من بيانات التدريب مثل أوزان: (Parameters) (المعلمتات) الشبكة العصبية أو معاملات الانحدار الخطي.
- هي القيم التي يتم تعيينها قبل عملية التدريب: (Hyperparameters) (الهايبر باراميتير) وتتحكم في كيفية تعلم النموذج، مثل عدد الطبقات في الشبكة العصبية أو معدل التعلم (learning rate).

4. Supervised Learning و Unsupervised Learning ما هو الفرق بين

- يعتمد على بيانات تحتوي على مدخلات: (Supervised Learning) التعلم المُشرف ومخرجات معروفة، حيث يتعلم النموذج منها التنبؤ بمخرجات جديدة بناءً على المدخلات.
- يتعامل مع بيانات بدون مخرجات: (Unsupervised Learning) التعلم غير المُشرف. محددة، حيث يحاول النموذج إيجاد أنماط أو مجموعات في البيانات.

5. Model Validation و Model Evaluation الفرق بين

- يشمل قياس دقة النموذج باستخدام مقاييس معينة بعد: (Model Evaluation) (تقييم النموذج) تدريبه، وذلك لتحديد كفاءته في التنبؤ.

- هو اختبار النموذج على بيانات لم يرها من قبل أثناء: (تقييم النموذج) **Model Validation**. التدريب بهدف تقييم قابليته للتعميم، وتحديد مدى أدائه على بيانات جديدة.

6. Gradient Descent و Stochastic Gradient Descent؟ قارن بين

- **Gradient Descent**: عملية تحسين يتم فيها حساب تدرج الكلفة باستخدام مجموعة البيانات الكاملة، وهي طريقة دقيقة لكنها بطيئة.
- **Stochastic Gradient Descent (SGD)**: يحسب التدرج باستخدام عينة واحدة عشوائية من البيانات في كل خطوة، مما يجعله أسرع ولكنه قد يكون أقل استقراراً.

7. Bias و Variance؟ ما الفرق بين

- هو الخطأ الذي يحدث عندما يكون النموذج مبسطاً بشكل مفرط ولا يستطيع: (الانحياز) **Bias**. استيعاب البيانات بشكل جيد.
- هو الخطأ الذي يحدث عندما يكون النموذج معقداً ويتأثر بالتفاصيل: (التباين) **Variance**. الدقة للبيانات، مما يؤدي إلى أداء ضعيف على بيانات جديدة.

8. في التصنيف؟ (Class Imbalance) ما هي طرق التعامل مع مشكلة توازن البيانات

- في التصنيف، قد تحتوي مجموعة البيانات على فئات غير متساوية من حيث عدد الأمثلة. هناك عدة طرق للتعامل مع هذه المشكلة، مثل:
 - (Oversampling) إما عبر زيادة عينات الفئة الأقل: (Resampling) إعادة التوازن (Undersampling) أو تقليل عينات الفئة الأكبر.
 - بدلاً من الدقة العامة F1-score مثل: استخدام مقاييس غير دقيقة.
 - إعطاء أهمية أعلى للفئة الأقل تمثيلاً أثناء: (Weighted Learning) التعلم بالوزن التدريب.

9. كيف يمكن تقييم أداء النموذج في مشاكل الانحدار؟ وما هي مقاييس التقييم المستخدمة؟

- يمكن تقييم أداء نموذج الانحدار باستخدام مقاييس مثل:
 - **Mean Absolute Error (MAE)**: تقيس الفرق المطلق بين القيم المتوقعة والفعالية.
 - **Mean Squared Error (MSE)**: تقيس مربع الفرق، وهي حساسة للقيم الكبيرة.
 - **R-Squared**: يقيس النسبة التي يستطيع النموذج تفسيرها من التباين في البيانات.

10. Linear Regression وكيفية تأثيره على النماذج مثل Regularization اشرح مفهوم Logistic Regression؟

- هو أسلوب لتجنب فرط التهيئة من خلال إضافة قيود على القيم: **(Regularization) التنظيم**:
القوى للمعاملات. يُستخدم نوعان رئيسيان:
 - **L1 Regularization (Lasso)**: يعاقب النموذج بتقليل بعض المعاملات إلى الصفر، مما يؤدي إلى نماذج أبسط.
 - **L2 Regularization (Ridge)**: يعاقب النموذج بشكل تدريجي بتقليل القيم الكبيرة للمعاملات لكنه لا يصل بها للصفر، مما يساعد على السيطرة على التباين.

11. بدلاً Precision في التصنيف؟ ومتى يُفضل استخدام Precision-Recall Tradeoff ما هو Recall؟

- **(Recall) والتغطية (Precision) في التصنيف**، هناك تبادل بين الدقة:
 - **Precision**: هي النسبة المئوية للتنبؤات الصحيحة من إجمالي ما تم التنبؤ به للفئة الإيجابية.
 - **Recall**: هي النسبة المئوية للتنبؤات الصحيحة من إجمالي الفئة الإيجابية في البيانات الأصلية.
 - عندما تكون التكلفة الناتجة عن التنبؤ الخاطئ كبيرة، مثل **Precision** يُفضل استخدام عند تصنيف بريد مهم كبير غير مرغوب.

12. ، ومتى يُنصح Linear Regression عن Polynomial Regression كيف تختلف باستخدامها؟

- **Polynomial Regression**: هو امتداد للانحدار الخطي يضيف حدوداً من درجات متعددة للمدخلات، مما يسمح بتمثيل أكثر مرونة للبيانات.
 - **يُفضل استخدامه** عندما تكون البيانات غير خطية ولكن لا تزال تتبع نمطاً بسيطاً يمكن تمثيله بتعددية حدود.
 - يُنصح بتوخي الحذر من فرط التهيئة، حيث قد يزيد تعقيد النموذج بتزايد درجة التعددية.

13. في تدريب Gradient Descent و Mini-Batch Gradient Descent ما الفرق بين النماذج؟

- **Gradient Descent:** هو خوارزمية تحسين تستخدم مجموعة البيانات الكاملة في كل تكرار لحساب الانحدار.
- **Mini-Batch Gradient Descent:** يجمع بين المزايا، حيث يقسم البيانات إلى مجموعات ، مما يوازن بين الدقة وسرعة التدريب (batches) صغيرة.

14. K-Fold في تحسين التعميم العام للنموذج؟ وما الفرق بين Cross-Validation و Leave-One-Out Cross Validation؟

- **Cross-Validation:** هو أسلوب لتقسيم البيانات إلى عدة مجموعات تدريب واختبار لضمان تعميم النموذج.
 - **K-Fold:** منها للتدريب والباقي للاختبار، K-1 مجموعات، ويستخدم K يقسم البيانات إلى مع تكرار العملية.
 - **Leave-One-Out:** يتم فيها استخدام عينة واحدة للاختبار والباقي للتدريب، ويتم تكرار العملية لكل عينة، مما يجعله أكثر دقة لكنه مكلف حسابياً.

تعريف الـ Overfitting :

هو عندما يتعلم النموذج بيانات التدريب بدقة عالية جداً، لدرجة أنه يبدأ بتعلم التفاصيل والضجيج الموجود في البيانات، وليس فقط الأنماط العامة. هذا يؤدي إلى أن يصبح النموذج قوياً في التنبؤ بالبيانات التي تدرب عليها، ولكنه يفشل في التعميم عند اختبار بيانات جديدة. بمعنى آخر، النموذج يصبح متكيفاً جداً مع بيانات التدريب ويعاني من ضعف الأداء على بيانات غير مرئية.

Overfitting كيفية معالجة الـ

: باستخدام تقنيات مختلفة، من أهمها **Overfitting** يمكنك تقليل الـ

1. استخدام بيانات أكثر:

- إضافة المزيد من بيانات التدريب، لأن النماذج الكبيرة أو المعقدة تميل إلى التعلم من أنماط محددة عندما تكون البيانات قليلة. المزيد من البيانات يجعل النموذج يتعلم أنماطاً أكثر عمومية.

2. التنظيم (Regularization):

- **L1 Regularization (Lasso):** تضيف عقوبة بناءً على حجم المعاملات، وتقلل بعضها إلى الصفر مما يبسط النموذج.
- **L2 Regularization (Ridge):** تقلل القيم الكبيرة للمعاملات بدون جعلها تساوي الصفر، مما يقلل تعقيد النموذج ويساعد على التعميم.

3. Cross-Validation استخدام:

- **Cross-Validation K-Fold** يقسم البيانات إلى أجزاء متعددة ويستخدم بعضها للتدريب والباقي للاختبار. هذا يسمح بمراقبة أداء النموذج باستمرار ومنع الإفراط في التهيئة.

4. التقليل من تعقيد النموذج:

- إذا كنت تستخدم نموذجًا معقدًا مثل شبكة عصبية كبيرة أو نموذج شجري عميق، يمكنك تقليل تعقيده. مثلاً، يمكنك تقليل عدد الطبقات أو العقد في الشبكات العصبية، أو تقليل عمق الشجرة في نماذج الأشجار.

5. Dropout في الشبكات العصبية إدخال:

- **Dropout (neuron)** هي تقنية خاصة بالشبكات العصبية يتم فيها إيقاف بعض العقد **Dropout** أثناء التدريب بشكل عشوائي. هذا يقلل من الاعتماد على العقد الفردية ويجعل النموذج أكثر مرونة.

6. Early Stopping (التنظيم المبكر):

- متابعة أداء النموذج على بيانات الاختبار خلال عملية التدريب، وعندما يبدأ الأداء في التدهور يتم إيقاف التدريب.

Semi-Supervised Learning: A machine learning approach that uses both labeled and unlabeled data to improve model accuracy.

Dot Product of Two Eigenvectors: Maximized when the eigenvectors are parallel, meaning they point in the same direction.

Normalization: The process of scaling data to a common range to ensure that different features contribute equally to the analysis.

Regularization: A technique used to prevent overfitting by adding a penalty to the loss function based on the magnitude of model parameters.

Solving Overfitting: Can be addressed by techniques such as cross-validation, regularization, pruning, early stopping, data augmentation, and simplifying the model.

Gradient Descent: An optimization algorithm that updates model parameters in the direction opposite to the gradient of the loss function to minimize it.

Imbalanced Data: A situation in machine learning where the classes are not represented equally, leading to biased models that favor the majority class.

Cnn → images

Rnn → text

Rnn → harder to train

Cnn → spatial data

Rnn → sequential data

El far2 ma been el regular dropout w el spatial drop

Regular : drops random neurons

Spatial : drops whole feature maps

الي جمب بعض بتبقي مرتبطة ببعض فا لو شلت واحد بس **neurons** و بتستخدم عشان ال منها ممكن الدنيا تبوظ فبتشيلها كلها

F1-score is like a balance between precision and recall. It tells you how good your model is at making correct predictions

Precision tells you how many of the items that your model labeled as positive were actually positive. If your model predicts a lot of positives, but many of them are wrong, then precision will be low.

Recall tells you how many of the actual positive cases your model was able to identify. If your model misses a lot of true positives, then recall will be low.

The F-2 score is essentially the F1 score's variant, merging precision and recall into a single score. However, in F-2 score, there's a more pronounced emphasis on recall compared to the conventional F-1 score. The F-2 equation is:
$$F-2 \text{ score} = (1 + 2^2) * (\text{precision} * \text{recall}) / (2^2 * \text{precision} + \text{recall}).$$