

[Machine Learning]

What is Machine Learning?

A set of **Algorithms** that gives the computers the ability to learn from data, and then make **predictions** and **decisions**.

ML vs DL vs Ai ?

Artificial Intelligence (Ai):

study/process which enables machines to **mimic** human behavior, through particular **algorithm**.

Machine Learning (ML):


ML is the **subset** of Ai.

ML is an Ai algorithm which allows system to **learn** from data and make decisions

Deep Learning (DL):

DL is the **subset** of ML.


DL is a ML algorithm that uses deep (more than one layer) **neural networks** to analyze data and provide output



Why Machine Learning ?

- As a part of the Ai revolution, machine learning will **transform** every **business** both online and offline – how decisions are made, how processes improve
- This technology will **redefine** many **industries**, such as: Healthcare, Financial services, Energy and many other fields that directly impact our lives
- The power of machine learning is allowing us to **solve** more complex problems, **faster** than any time before.

How Does it Work ?



What is a machine learning Model ?

- A “model” in machine learning is the **output** of a machine learning algorithm run on data.
- The best analogy is to think of the machine learning model as a “**program**.”
- Model == Model Data + Prediction Algorithm

Data Mining:

- The process of **extracting** useful information from a huge amount of data
- It's a **tool** used by humans to discover new, accurate, and useful patterns in the data.

You first identify **business goals** and data mining goal, then you start this process:



Machine Learning vs Data Mining :

Machine Learning


- **training algorithms** to make predictions or decisions
- **less** human effort required after design
- **Used** in image and speech recognition, recommendations, spam filters.
- **Regression, classification, clustering, deep learning**
- **Predictive** and **prescriptive**

Data Mining


- **discovering** patterns and relationships in large datasets
- **more** human interference is required in it.
- **Used** in finance, marketing, and healthcare, analysis to identify patterns and trends
- **Clustering, association rule mining, outlier detection**
- **Exploratory** and **descriptive**

Machine Learning Process Work Flow:

High level ML Workflow



Detailed ML Process Workflow



Also called the ML **life-cycle**, this high-level workflow gives an intuition about the overall work through the ML process.

A more detailed version is present to give a deeper insight about the **actual steps** in each phase.

About Data Cleaning (Scrubbing):

Data cleaning is the process of fixing or removing **incorrect**, **corrupted**, incorrectly **formatted**, **duplicate**, or **incomplete** data within a dataset. When combining multiple data sources, there are many opportunities for data to be duplicated or mislabeled. **garbage in, garbage out!**


If data is incorrect, outcomes and algorithms are unreliable, even though they may look correct.

Steps:

1. **Duplicate & irrelevant observations**
removing duplicated to avoid inaccuracy and skewness.
2. **Structural errors (normalize & standardize)**
Handling strange naming conventions, typos
incorrect capitalization, inconsistent data formats.
3. **Filter unwanted outliers**
handling outliers, such as **removing** them or **imputing** them with more reasonable values.
4. **Handle missing data**
handle them by **imputing** missing data, **dropping** the missing data or **leaving** it as-is
5. **Verify data quality**
checking for consistency between different parts of the dataset, and validating the accuracy of the data against external sources



Types of Machine Learning:



Basic Terminology:

Labels

A **label** is the thing we're predicting—the **dependent** y variable in simple linear regression. The label could be the future price of wheat, the kind of animal shown in a picture... etc.

Features

A **feature** is an input variable—the **independent** x variable in simple linear regression. Features could either be:


- **Qualitative**: categorical data (genders, nationality, marital status...)
- **Quantitative**: numerical data, both discrete and continuous (price, temperature ...etc.)

Examples

An **example** is a particular instance of data, **x** (**feature vector**). We break examples into two categories:


- **labeled** examples: includes both feature(s) and the label.
- **unlabeled** examples: contains features but not the label.

Supervised vs Unsupervised:




Supervised machine learning:

You supervise the machine while training it to work on its own. This requires **labeled** training data



Unsupervised machine learning

Unsupervised learning: There is training data, but it's **unlabeled**



Supervised Learning in Detail:

The goal of supervised machine learning is to learn a **mapping function** that can accurately predict the target variable (or output) for new, unseen input data.

1- Step One: Preparing the data (data split)

first of all, the data is divided into 3 sets:

1. **Training set:** portion of the labeled data used to train the machine learning model.
2. **Validation set:** portion of the labeled data used as a reality check **during/after** training to:
 - Ensure the model can handle new, unseen data
 - Choosing the model with minimum loss *
 - Tune the model's hyperparameters**
 - Prevent the model from overfitting***
3. **Test set:** portion of the labeled data, used **after** completing the training to check how **generalizable** the final chosen model is.

data splitting techniques:

Various data splitting techniques can be used like :

- **Random** (Holdout method)

the most basic and straight forward method, but it comes with a drawback,

For **example**, if a dataset has 1000 images, of which 800 belong to the category: "dog" and 200 belong to the category: "cat," it might so happen that the training set consists only dog images, while the validation set consists of only cat images!

- **Stratified**

dividing the labeled data into subsets based on the distribution of the target variable.


Suppose a dataset consists of 1000 images, of which 600 are dog images and 400 are cat images. In that case, stratified sampling ensures that 60% of the images are of category "dog" and 40% are of category "cat" in the training and validation sets. can be used in **conjunction** with the holdout method or k-fold cross-validation.

- **Cross-Validation** (k-fold cross validation)



a more robust technique for data splitting, where we divide the labeled data into K equal-sized subsets, or "folds". The model is trained K times, each time using a different fold as the validation set and the remaining folds as the training set. The performance of the model is then averaged across the K runs.

When used with "Stratified" method, it creates the Stratified k-fold cross-validation

Stratified K-Fold Cross Validation



Target Class Distribution



2- Step Two: Choosing an Algorithm

Based on the task at hand, we can one of **two** categories of supervised learning:


Regression

Used to predict **continuous** values such as **sales**, **salary**, **weight**, or **temperature**.

For example: A dataset containing features of the house such as size, number of bedrooms, number of baths, neighborhood, etc. and the price of the house, a Regression algorithm can be trained to learn the **relationship** between the features and the price of the house.

@ Common Regression Algorithms:

- Linear Regression
- Polynomial Regression
- #Decision Tree Regressor*
- #Random Forest Regressor*
- Neural Networks



Classification

Used for predicting **discrete** outcomes, if the outcome can take two possible values such as [True or False], [Dog or Cat], [Yes or No], it is known as **Binary Classification**. When the outcome contains more than two possible values [dog, cat, lizard...], it is known as **Multiclass Classification**.

@ Common Classification Algorithms:

- k-Nearest Neighbor (**k-NN**)
- Support Vector Machine (**SVM**)
- Naïve Bayes
- #Decision Tree Classifier*
- #Random Forest Classifier*
- Logistic Regression

@ Evaluation Metrics:

Confusion Matrix

N= 200	Predicted: Cat	Predicted: Dog
	True Positive	False Positive
Actual: Cat	60	10
Actual: Dog	False Negative	True Negative
	20	110


Recall: how many relevant items are retrieved?

Calculated as $= TP / (TP + FN)$.

Precision: how many retrieved items are relevant?

Calculated as $= TP / (TP + FP)$.


F1-Score: The harmonic mean of precision and recall.



Supervised Algorithms Recap (AR) //

1- k-Nearest Neighbor (k-NN)

دى خوارزمية تصنيف (Classification), الغرض منها بعد ما تدرب المودل بتاعك انها تقدر تحدد العينة الجديدة الى دخلت تقع فى انهى تصنيف من الى المودل اتدرب عليهم ...



بنعمل ده عن طريق مقارنة العنصر الجديد باقرب جيرانه من ال data points الى حواليه , والرمز k بيشير لعدد الجيران الى هنشغل عليهم ونحسب مسافة العنصر الجديد منهم عشان نعرف لينتمى لمين بنسبة اكبر .

2- Naïve Bays

خوارزمية تصنيف معتمدة على نظرية Bays فى الاحتمالات وكلمة Naïve هنا (واللى معناها ساذج) بترمز لافتراض ان وجود صفة أ فى شئ ملهاش علاقة بوجود صفة ب فيه ! بمعنى ان كل صفة "مستقلة" وليها نسبة خاصة بيها انها تكون موجودة فى الشئ ده أو لا .

مثال لو عندك قطط و كلاب , وعندك الصفات دى (ودان صغيرة, فرو, لون برتقانى, ديل طويل)...

فانت بتحسب نسبة وجود كل صفة "لوحدها" عند الكلاب و القطط

ولما يجيلك كائن جديد بتشوف نسبة كل صفة من دول عندو ايه

وبعدين تحسب "احتمال" كونه كلب او قطه حسب مجموع نسب الصفات دى.

$$P(c|x) = \frac{P(x|c)P(c)}{P(x)}$$

Labels: Likelihood, Class Prior Probability, Posterior Probability, Predictor Prior Probability

$$P(c|X) = P(x_1|c) \times P(x_2|c) \times \dots \times P(x_n|c) \times P(c)$$

c بتمرز لل class او التصنيف / x بتمرز لل features او الصفة

3- Logistics Regression

خوارزمية تصنيف ثنائية (Binary Classification) بتجاوبك بنتيجة من اتنين اه/لا , ناجح/راسب , مقبول/مرفوض ... الخ


● فكرة عملها انه الصفة المتغير (x independent variable) فى بينها وبين النتيجة المراد توقعها (y dependent variable) علاقة خطية وبناءا عليه نقدر نتوقع النتيجة النهائية حسب درجة الصفة المتغيرة دى


مثال, لو جالنا شخص عمره 32 سنة , فحسب الموديل ده

هو سنه اقل من الحد الفاصل Threshold Value (40 سنة)

يعنى احتمالية انه يشتري التأمين اقل , فبنصنفه على انه (No)

لانه اقرب للفئة دى احصائيا.





Support Vector Machine (SVM) -4

خوارزمية تصنيف فكرتها الاساسية قائمة على رسم
حد فاصل Hyperplane يقسم الداتا لمجموعتين بافضل شكل
 ممكن , عشان لما تيجي داتا جديدة اقدر اصنفها بسهولة


• والمقياس لاختيار الخط الفاصل ده ان المسافة بين
 الخط بتاعنا وبين اقرب نقط داتا تكون اكبر ما يمكن
 من كلا الطرفين ونسميها **Maximum Margin** .

• مصطلح **Support Vector** بيطلق على ال **datapoints** الى بتكون على اطراف
 ال **Hyperplane** واللى بتساعدنى فى التصنيف بحيث لو جاتلى داتا جديدة
 بصنفها تبع المجموعة الاقرب لل Support Vector ده .

Decision Trees -5


الخوارزمية دي ممكن تستخدم لتوقع تصنيف معين وساعتها
 بنسميها : **Classification Tree** او لتوقع قيمة معينة وساعتها
 بنسميها : **Regression Tree** .

الشجرة بتاعتنا عامة بيكون ليها نقطة بداية بنسميها **Root Node**
 و بينزل منها فروع **Branches** او **Decision Nodes**
 وفى النهاية عندنا ال **Leaves** واللى بتشاور على تصنيف معين



👉 فى حالة ال **Classification Tree** اهم حاجة هو ال **Split**
 بمعنى انك تحدد هتبدأ بانهى صفة ك **Root Node** , والقرار ده
 بيتبنى بكذا طريقة زي: **Entropy** و **Gini Impurity** ...
 والاخيرة دي بتبنى على معيار ال **Impurity** وهو مستوى
 نقاء و جودة ارتباط الصفة دي بالنتيجة النهائية ,
 وكل ما كانت قيمة ال **impurity** اقل كل ما كان جودة
 الصفة وارتباطها بالنتيجة النهائية اعلى.

• لما نيجي نقرر انهى صفة هتكون هى ال **Root Node**
 بنحسب ال **Gini Impurity** لكل صفة رئيسية **Feature** وبعدين
 ناخذ الصفة **الاكثر نقاءا** (اقل impurity) وتبقى هى رأسه الهرم



وهكذا بنستمر على نفس الطريقة بحيث ال **Leaf** النهائية
 تكون قرار حاسم قدر الامكان (**Impurity = 0**)


Random Forest -6

دى كمان خوارزمية بتستخدم لتوقع تصنيف معين او قيمة معينة (Classification & Regression)

• الخوارزمية دى بتعالج مشكلة التداخل **Overfitting** الى كانت بتحصل فى خوارزمية ال Decision Tree لما بتقابلك داتا فيها كذا Feature وبتبقى الشجرة بتاعتك متشعبة وعميقة جدا (Deep & Complex)

• كمان بترفع نسبة الدقة **Accuracy** بتاعة النتيجة النهائية باستخدام مفهوم ال **Bagging** , وهو ان بتجمع نتيجة كذا خوارزمية متشابهة سوى (كذا Tree) وفى الآخر بتعمل اما **Voting** لو غرضك التصنيف او **Average** لو غرضك رقم او قيمة عددية.

• الخطوة الاولى المختلفة هنا انك بتقسم ال Training data لعدد من الأجزاء بطريقة اسمها **Bootstrap Sampling** وكل جزء بتدخله على شجرة لوحده تتدرب عليه وتديك نتيجة. والخطوة الاخيرة زى ما قلنا انك بتجمع النتائج دى كلها وبناءا عليها بتاخذ قرار نهائى.



Linear Regression -7



اول وابسط خوارزمية لتوقع قيمة مجهولة بناءا على علاقة **Correlation** بينها وبين قيمة / عدة قيم معلومة , زى مثال العمر والطول هنا

على محور السينات **x** independent variable بنحط قراءات الصفة المتغير على محور الصادات **y** dependent variable بنقيس قيمة النتيجة المطلوبة المسافة بين اى نقطة وبين الخط المرسوم بتسمى **residual (R)**

• اول واهم خطوة فى تنفيذ الموديل بعد عرض الداتا على Scatter plot مثلا , هو اختيار مكان خط الانحدار **Regression line** الى هيوضحنا **قوة** و **اتجاه** العلاقة بين الصفة المتغيرة **x** والقيمة المراد استنتاجها **y**

• من اشهر الطرق فى اختيار خط الانحدار هى ال **Least Squares** والى فيها ببساطة بنحسب مجموع **R²** بتاع النقط لكل خط افتراضى , وبنختار الخط الى قيمة **R²** الكلية عنده اصغر قيمة

• خلاص كذا بعد ما بنحدد الخط بتاعنا والموديل يبقى جاهز , بندخل داتا للصفة **x** وهو بيتوقع **y**



Unsupervised Algorithms Recap (AR) //

Clustering -8


خوارزمية تجميع داتا , هدفها انها تجمع العينات الى في بينها صفات مشتركة
وعندنا كذا اسلوب فى التجميع على حسب حالة الداتا :

Exclusive Clustering (K-Mean) :

يا ابيض يا اسود , مفيش وسط ... العينة لازم تنتمى لمجموعة واحدة بس

Overlapping Clustering (C-Mean) :

ابيض واسود ورمادى ... مفيش مشكلة ان عينة تنتمى لأكتر من مجموعة فى نفس الوقت



• من اشهر الخوارزميات فى التجميع واللى هنركز عليها هي k-Mean Clustering

وطبعاً زى ما اخدت بالك هي بتتبع اسلوب ال Exclusive Clustering

فى اربع خطوات بنمشى عليهم عشان نوصل للنتيجة النهائية:

1- تحديد عدد المجموعات (K)

وده ليه طرق رياضية زى ال Elbow Method بس نقدر نبدأ برقم عشوائى وليكن 3 مثلاً

2- اختيار مكان المحاور Centroids عشوائياً

دور المحاور دي انك بتقيس البعد العمودى لكل نقطة

وتديها لون حسب اقرب محور ليها

3- حساب معدل التقارب Convergence لكل مجموعة

وده عن طريق حساب متوسط بعد النقط عن المحور

Mean Distance فى المجموعة الواحدة. خليك فاكر الرقم ده !



(كلمة Mean فى الاسم جاية من هنا)

4- اختيار مكان جديد للمحاور!

وتهعيد خطوة رقم 3 تانى وتحسب معدل التقارب

الخطوة دي هتكرر عدد مرات معين (Iterations) محدد مسبقاً

او لحد ما توصل لافضل معدل تقارب ممكن !



Association

People who buy X tend to buy Y

People who buy A+B tend to buy C



Association Rule -9

قاعدة الارتباط هي مفهوم يستخدم في ال Data Mining وال Machine Learning ويشير لوجود ارتباط بين عنصرين او اكثر

- يستخدم بشكل واسع في مجال التجارة لفهم الانماط الشرائية عن طريق Market Basket Analysis والى فيها بتدرس ارتباط العناصر الى اشتراها العملاء ببعض
- الغرض الاساسى للمتاجر هو عامة زيادة المبيعات.
- وطبعا معلومة زى دي ممكن تفيدهم باكثر من شكل زى:

- تنظيم رفوف العرض بحيث المنتجات الى بتتباع سوتكون قريبة من بعض فتعلى نسبة المبيعات
- تسويق منتجات معينة مع بعضها، بناءا على قوة الارتباط بينهم (زى منتجات الاطفال والعربات ..الخ)
- استهداف شرائح من العملاء بعروض وخصومات خاصة بناءا على نمطهم الشرائى

ID	Items
1	{Bread, Milk}
2	{Bread, Diapers, Beer, Eggs}
3	{Milk, Diapers, Beer, Cola}
4	{Bread, Milk, Diapers, Beer}
5	{Bread, Milk, Diapers, Cola}
...	...

market basket transactions

{Diapers, Beer} Example of a frequent itemset

{Diapers} → {Beer} Example of an association rule

- من اشهر الخوارزميات المستخدمة في ال Association Rule Mining هي Apriori Algorithm والى بتستخدم مبدأ " التكرار Frequency " عشان تستنج وجود Association بين العناصر المطلوبة .
- بناءا على تحليل عمليات الشراء السابقة للعملاء (Transactions) نقدر نستخرج المجموعات المتكررة frequent itemset والى منها نقدر نعرف العناصر المرتبط ظهورها ببعض .

Model Evaluation Metrics

Bias: the difference between the predicted values and the actual values.

high-bias results in **underfitting**, the model is **too simple** and can't capture trends in the dataset.

Variance: the variability of the model's predictions for different training sets.

high-variance results in **overfitting**, the model is **too complex** and performs well on the training data but poorly on new, unseen test data.

The bias-variance trade-off:

As the complexity of the model increases, the bias decreases but the variance increases, and vice versa.

ROC (Receiver Operating Characteristic) : a graphical plot that shows the performance of a **binary classifier** system as its discrimination **threshold** is varied. such as **logistic regression**, **decision trees**, **random forests**, **support vector machines**.

